



Plataforma de processamento de dados sísmicos como serviço em Nuvem

G. L. da Silva

E. Borin

Relatório Técnico - IC-PFG-18-01

Projeto Final de Graduação

2018 - Dezembro

UNIVERSIDADE ESTADUAL DE CAMPINAS
INSTITUTO DE COMPUTAÇÃO

The contents of this report are the sole responsibility of the authors.
O conteúdo deste relatório é de única responsabilidade dos autores.

Plataforma de processamento de dados sísmicos como serviço em Nuvem

Guilherme Lucas da Silva

Edson Borin

Resumo

Este trabalho é um relatório parcial de um projeto temático plurianual, visando o estudo comparativo de diversas espécies de cervejas nativas do sub-continente brasileiro. A realização deste trabalho contou com o suporte financeiro do CNPq e FAPESP, e foi imensamente facilitada pela infraestrutura de pesquisa cervisiaca instalada no Campus da UNICAMP.

Com base nessas pesquisas, determinamos que a altura da cerveja h e a altura da espuma e satisfazem aproximadamente a inequação $(\sqrt{e^2 + h^2} + 2he)^3 \leq \exp(3 \log K_0^*)$, onde K_0^* é a altura do copo. Esta fórmula é válida, aparentemente, inclusive para espécies mais pigmentadas, como *Malzbier*. Em vista disso, e dos resultados análogos obtidos por A. B. Stémio em experiências com *Guaraná* e *x-Cola*, conjecturamos que a fórmula pode ser aplicada (com pequenas modificações) também a *Champagne* e outros líquidos de composição similar.

1 Introdução

Computação em Nuvem é um conceito que está cada vez mais presente no cotidiano de todas as pessoas. Mesmo sem perceber, uma quantidade gigantesca de aplicações que usamos hoje em dia lançam mão desse conceito tão central para o desenvolvimento econômico e tecnológico de nossa sociedade contemporânea. Esse conceito se baseia na capacidade de usarmos o poder computacional de uma infinidade de serviços como Máquinas virtuais, Bancos de Dados e Redes Virtuais sem necessariamente possuímos máquinas físicas com tais serviços instalados e configurados, ainda sendo possível, de maneira simples, exportar tais serviços e mecanismos para vários usuários ao redor do mundo. Segundo o artigo Cloud Computing Security: A Systematic Literature Review [?], computação em nuvem é um modelo de rede que torna possível o acesso sob demanda de recursos computacionais configuráveis. Entre as modalidades principais de serviços de computação em nuvem, temos três categorias mais relevantes:

- **IaaS(Infrastructure as a Service):** essa é a maneira que dá mais responsabilidade ao usuário. Essa modalidade te dá máquinas virtualizadas que você deve gerenciar instalação de programas, configurações e etc. Exemplo disso são máquinas virtuais que rodam sistemas operacionais GNU/Linux e são acessadas remotamente.
- **PaaS(Platform as a Service):** Aqui, o usuário não precisa se preocupar com pacotes de sistema, softwares e configurações. Esse sabor de computação em nuvem,

tenta facilitar para desenvolvedores publicares suas aplicações. Isso significa que se, por exemplo, um usuário quiser publicar uma aplicação, não vai precisar se preocupar em instalar compiladores nem pacotes necessários para rodar a aplicação naquela determinada linguagem.

- **SaaS(Software as a Service):** essa é a modalidade que traz menos autonomia para o desenvolvedor, sendo que, através dela, todo o recurso é gerenciado pelo provedor de nuvem que é consumido. Alguns exemplos que podemos citar para ilustrar são bancos de dados como serviço, onde o usuário não se preocupa com nenhum tipo de infraestrutura, somente usa o endereço que o provedor cede e faz uso das possibilidades de armazenamento que a plataforma oferece.

Entre as vantagens de se adotar um modelo de computação em nuvem ao invés de investir em realmente adquirir máquinas físicas, podemos citar:

- **Custo:** devido a possibilidade de pagar somente pelo o que está usando, ou seja, caso algum recurso está sendo pouco aproveitado, basta desligá-lo, usuários desse tipo de plataforma não gastarão para manter sistemas parados.
- **Escalabilidade:** A computação em nuvem permite que, caso a aplicação precise de muito mais poder computacional do que possui no momento, seja extremamente simples aumentar o número de instâncias ou o tamanho das máquinas, para atender mais usuários, gerando assim, mais receita.
- **Foco na aplicação:** desenvolvedores podem focar totalmente em escrever suas aplicações, sem a preocupação de gerenciar infraestrutura e plataforma.

Entre os principais players de nuvem pública atualmente temos gigantes como Microsoft Azure¹, Amazon Web Services² e Google Cloud Platform³, oferecendo opções extremamente diversas para computação em nuvem, desde máquinas virtuais até mesmo bancos de dados gerenciados, onde a preocupação de gerenciamento fica totalmente do lado do provedor do serviço.

Aplicações de HPC (High Processing Computing, computação de alto processamento, na tradução) são uma gama de programas que necessitam de muito poder computacional para completar as seus objetivos. Entre essas tarefas, estão o processamento de dados sísmicos, que são obtidas de maneira bruta e precisam de um trabalho muito pesado de tratamento para que algumas conclusões possam ser feitas a partir dele. Segundo o texto [?], Supercomputação é usada para realizar operações matemáticas em alta velocidade. HPC é como supercomputação, mas com o poder computacional de cluster computacionais. Ainda hoje, muitas dessas operações são feitas em servidores em institutos de pesquisas, por exemplo, podendo levar a um custo excessivo, trabalho excessivo para gerenciamento de infraestrutura além de baixíssima agilidade e flexibilidade quanto a infraestrutura. Assim, tais aplicações podem tirar muito proveito dos provedores de nuvem citados acima.

¹Plataforma de Computação em Nuvem da Microsoft <https://azure.microsoft.com/>

²Plataforma de Computação em Nuvem da Amazon <https://aws.amazon.com/>

³Plataforma de Computação em Nuvem do Google <https://cloud.google.com/>

2 Objetivos

Esse trabalho tem como objetivo desenvolver uma plataforma Open Source que torne extremamente simples para usuários que não conhecem conceitos de Computação em Nuvem rodarem suas aplicações. Entre os princípios do Open Source citado no Debian Social Contract [4]: Redistribuição livre, o software deve ser distribuído com o código fonte, trabalhos derivados, entre outros. A princípio, foram usadas aplicações para a prova de conceito. O desejado para o final da plataforma era que os usuários conseguissem processar os trabalhos sísmico sem nenhum conhecimento de Nuvem. Ao final, esperamos a criação de uma plataforma web, que tinha como principais funcionalidades:

- **Submissão e gerenciamento de dados:** Essa funcionalidade é a responsável pelo upload de dados que serão usados nos processamentos, além de consultar quais dados foram submetidos, baixá-los e também excluí-los, caso necessário.
- **Submissão e gerenciamento de binários:** esse componente do projeto é extremamente semelhante com a que detalhamos acima, porém, ao invés dos dados sísmicos, os artefatos que são gerenciados são os binários das aplicações que serão utilizados nos processos.
- **Definição de tarefas sísmicas:** Utilizando os dados e binários submetidos a partir das duas funcionalidades citadas anteriormente, o objetivo era conseguir lançar um processamento que combina os dados e binários, além dos argumentos necessários.
- **Obtenção dos resultados:** Ao final dos processos, é desejado que se consiga obter todos os resultados desse de maneira simples e rápida.

3 Relevância

Ao buscar por outras soluções que tem o mesmo intuito da plataforma que esse trabalho tem por objetivo desenvolver, notamos a sua extrema relevância, uma que vez que é extremamente difícil achar outros softwares open source que executam tal tarefa. Além da unicidade que o trabalho possui no cenários atual, ele se torna relevante já que ele pode abstrair os novos conceitos e a curva de aprendizado que vem junto com a computação em nuvem. Assim é possível tirar proveito de todos os benefícios que foram citados acima, levando a possibilidade de um uso muito mais inteligente dos recursos, baixando custos e aumentando a produtividade.

4 Procedimento

Para o sucesso final do projeto, ao começo dele, foi decidido que faríamos uma plataforma web. Essa foi a decisão devido a facilidade de desenvolver para esse tipo de plataforma, além do alcance gigantesco que plataformas web possuem, já que é praticamente obrigatório nos dispositivos que os usuários poderiam usar para acessar o sistema (smartphones e computadores) possuir um navegador de internet instalado. Além disso, vale ressaltar que desde

o início do projeto todo o código estava totalmente aberto no Github⁴, já que foi uma premissa desde o início do projeto que este seria Open Source.

Ao iniciar a análise do problema, foi possível notar que uma arquitetura de nuvem que se encaixa muito bem nesse problema é a de Work Queues(Filas de Trabalho), que segundo Brendan Burns em seu livro *Designing Distributed Systems*, "Em um sistema de filas de trabalho existe uma trabalho em batch para ser executado. Cada parte do trabalho é independente do outro e pode ser executado sem nenhuma interação" [3]. Isso é exatamente o que foi buscado, uma vez que os trabalhos eram intensivos, demoravam um tempo para serem reproduzidos e eram independentes um do outro. Assim, o que gostaríamos era que trabalhos fossem submetidos a uma fila e, alguma unidade de computação o usasse para executar uma definição de trabalho.

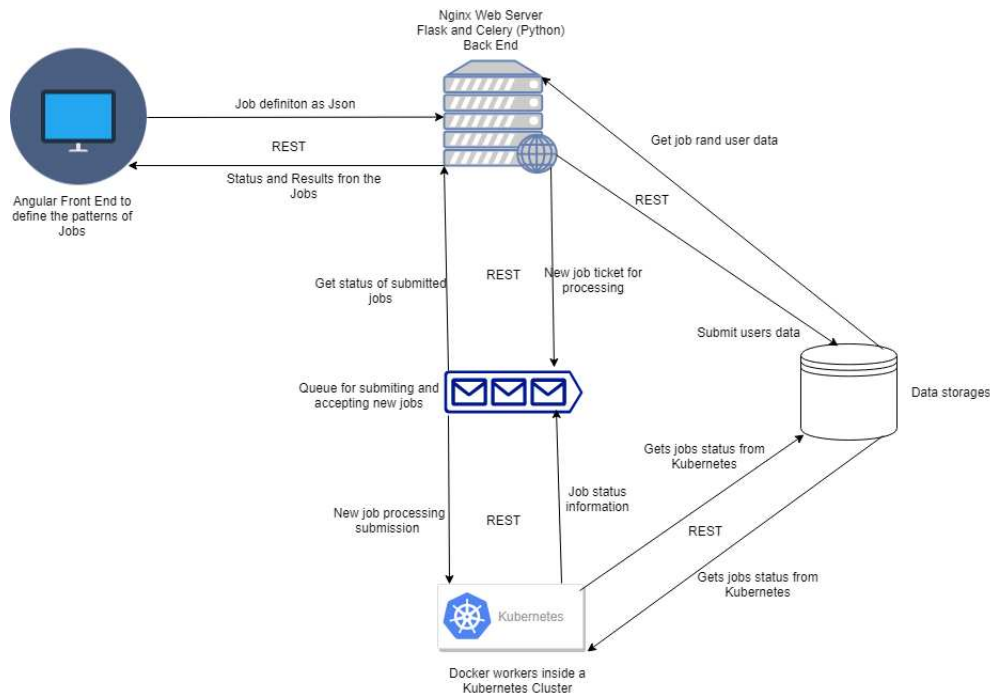


Figura 1: Arquitetura inicial do projeto e exemplo de filas da trabalho distribuídas

A imagem 1 ajuda a explicar como é o funcionamento dessa arquitetura e a arquitetura inicial do projeto.

Então, a plataforma foi separada em duas grandes partes:

- **Front-End:** A parte que o usuário realmente vê, o código que irá rodar no navegador do seu dispositivo. (Colocar alguma citação)
- **Back-End:** Essa é a porção da plataforma responsável por características que são invisíveis ao usuário. Entre elas, podemos citar acesso ao banco de dados, autenticação,

⁴Serviço para compartilhamento de código fonte www.github.com

processamento de dados, submissão de dados para a nuvem, etc.

Existem alguns componentes que foram usados em comum entre essas duas partes:

- **Docker**⁵: uma maneira muito simples de empacotar as aplicações, isolando dependências, garantindo que o deploy sempre é feito da maneira correta. Assim, é possível entregar as aplicações completas, com todos os requisitos necessários instalados, o que dá uma agilidade enorme durante o ciclo de desenvolvimento.
- **Nginx**⁶: Servidor web open source extremamente escalável e fácil de configurar. Foi usado tanto para servir o back end quanto o front end. A outra opção para esse trabalho seria o Apache Web Server, porém o Nginx se mostrou mais simples e rápido de ter aplicações rodando.

4.1 Front End

Para o desenvolvimento do front end, foram definidas de antemão como seria a composição geral das telas e como seria o fluxo da aplicação. Assim, foi decidido que o layout geral das telas, seriam:

SPaaS		User	Sign out
Login			
Email			
<input type="text"/>			
Password			
<input type="password"/>			

Figura 2: Página de Login

A figura 2 mostra como definimos quais informações deveriam estar na tela para que o usuário pudesse se conectar a plataforma. Como mostrado, as informações necessárias para logar no sistema eram email e senha que foram previamente cadastrado.

A figura 3 deixa claro quais foram as informações que eram requeridas para se criar uma conta no sistema.

⁵Programa que realiza virtualização em nível de SO, também conhecido como containerização <https://www.docker.com/>

⁶Servidor Web Open Source <https://www.nginx.com/>

SPaaS		User	Sign out
-------	--	------	----------

Create Account

Email

Password

Confirm Password

Figura 3: Página de criação de conta

SPaaS	Borin	Sign out
-------	-------	----------

Definitions

Menu
Definition
Status
Results

Jobs name

Code

Running Command

Job Data

Figura 4: Página de definição dos trabalhos

A figura 4 exemplifica como imaginamos a tela de definição de um trabalho para ser executado. Nesse primeiro protótipo, foi pensado que somente as informações mostradas na tela, eram o suficiente.

O protótipo da tela de status dos trabalhos está mostrada na figura 5. Extremamente simples a princípio, uma tabela mostrando o status de cada trabalho.

A ultima figura ?? mostra como foi pensada a obtenção dos resultados.

Vale ressaltar que essa ideia inicial foi considerada com poucas das funcionalidades que realmente eram relevantes para a plataforma. Assim, o fluxo de todo o trabalho foi repensado para algo mais próximo do representado na figura 7. Nesse fluxo definido, os quadrados representam as telas, com suas respectivas interações com as camadas de armazenamento que são necessárias para completar suas tarefas com sucesso. Assim, entrando

SPaaS

Borin

Sign out

Status

Menu
Definition
Status
Results

JobID	Used Time	Status
1	10 minutes	Completed
2	2 minutes	Enqueued
3	4 minutes	Processing
4	10 minutes	Completed

Figura 5: Página de observação do status

SPaaS

Borin Sign out

Results

Menu
Definition
Status
Results

JobID	Results File	Final value
1	result_1.json	12
2	result_2.json	14
3	result_3.json	14
4	result_4.json	28

Figura 6: Página de obtenção dos resultados

no detalhe de cada componente da solução:

- **Data Management:** Componente responsável pelo gerenciamento dos dados sísmicos da plataforma. A intenção nesse componente é ser capaz de adicionar, remover e movê-los de um tipo de armazenamento mais caro (porém mais rápido) para um mais barato, ligeiramente mais lento.
- **Flow Management:** Componente responsável por determinar uma sequência de passos que devem ser feitas para completar uma tarefa. Diferente dos trabalhos (Tasks), aqui a definição é de um conjunto de tasks, encadeadas para obter um resultado maior.
- **Tools Management:** Essa funcionalidade procura realizar o gerenciamento dos binários que serão executados. Assim como o componente responsável pelo gerenci-




Figura 7: Fluxo entre os componentes da plataforma

amento dos dados, esse componente busca dar a possibilidade de adicionar, mover e excluir binários da plataforma.

- **Running Tasks:** Nessa tela, é desejado que o usuário consiga ver qual é o status dos processamentos que iniciou. Status como Pendente e Pronto são alguns dos possíveis.
- **New Tasks:** Responsável por definir novas tarefas a serem rodadas. É desejado que as características necessárias para essa definição sejam binário, dado sísmico e argumentos para a execução acontecer com sucesso.
- **Results:** Os resultados dos processamentos executados estarão aqui, organizados pela execução que o gerou.

Como tecnologias para o desenvolvimento da nossa plataforma, especificamente para o front end, foram escolhidas as seguintes tecnologias:

- **Angular**⁷: Framework(link abaixo) para desenvolvimento de aplicações web Open Source, desenvolvido inicialmente pelo Google e agora também mantido pela comunidade. Usa como linguagem de desenvolvimento o Typescript⁸. A escolha desse framework aconteceu uma vez que ela é extremamente produtiva e por ser um framework completo, já encapsulando todo o conceito de serviços, estilo de página e linguagem de marcação, roteamento. Assim, com esse framework ainda é necessário conhecer linguagens de marcação como HTML(link) e CSS (link), mas a junção de todos esses conceitos fica muito mais simples.
- **Bootstrap**⁹: Frameworks que possui o estilo de vários componentes web prontos, como tabelas, menu laterais, barras superiores, etc. É o que muitos sites usam hoje em

⁷Framework Open Source para desenvolvimento web <https://angular.io/>

⁸Linguagem criada pela Microsoft. Um superset do JavaScript <https://www.typescriptlang.org/>

⁹Conjunto de ferramentas Open Source que ajuda na estilização de páginas <https://getbootstrap.com/>

dia, como é o caso do github Estilizar páginas web pode ser um trabalho extremamente complicado e demorado, por isso optamos por usar um framework. Existem outros frameworks CSS interessantes, porém poucos tem a maturidade do bootstrap.

Foi garantido que o deploy fosse feito da maneira mais simples e flexível para o cliente. Então, foi usado o servidor web Nginx para isso. Além disso, também foi disponibilizado um Dockerfile, que possibilita o deploy da solução de maneira extremamente simples e direta sobre Containers Docker.

4.2 Back End

Ao início do desenvolvimento do back end, buscamos definir quais seriam as melhores tecnologias para esse componente, além de definir como seriam as rotas e contratos que a API(link) do back end iria expor para que o front end pudesse consumir de forma eficaz e direta, garantindo assim, um total desacoplamento entre os dois componentes. Assim, os componentes que decidimos para o back end foram os seguintes:

- **Python¹⁰**: Linguagem criada por Guido Van Rossum, extremamente relevante nos dias de hoje devido a sua enorme gama de aplicações, que vão desde embarcados até sistemas de análise de dados de alto desempenho. A escolha dela foi devido principalmente a bibliotecas muito maduras para desenvolvimento de API's back end, filas de trabalho distribuídas e conectores com bancos de dados.
- **Flask¹¹**: Framework para desenvolvimento de APIS para Python. Foi escolhido devido a extrema agilidade para colocar uma API rodando. Além disso, é muito simples entender como a aplicação está funcionando, fator muito crítico para decidirmos na escolha desta, uma vez que o projeto tem como premissa ser Open Source e facilitar o entendimento de todos que o usam. Ao invés de Python/Flask, foram cogitadas também ASP .NET com C# e NodeJS. A primeira foi descartada devido a complexidade para simplesmente criarmos uma API. NodeJS não foi escolhido devido a dificuldade que novos programadores podem enfrentar para compreender as funcionalidades em um primeiro momento, quando fossem aumentar o projeto.
- **Celery¹²**: Uma vez escolhido Python e Flask como ferramentas para o desenvolvimento da solução, foi muito natural a escolha do Celery como ferramenta para trabalhar com filas de trabalho. Existem muitos casos de sucesso espalhados pela internet de engenheiros e desenvolvedores que usaram essa combinação com total eficácia. O Celery é um componente do Python que é o responsável por gerenciar, submeter e obter resultados de uma fila de trabalho, de uma maneira muito simples. Além disso, dá suporte a vários componentes de mensageria, como por exemplo, RabbitMQ¹³, Redis, Amazon SQS¹⁴.

¹⁰<https://www.python.org/>

¹¹Framework Web Open Source para Python <http://flask.pocoo.org/>

¹²Framework Open Source para tarefas distribuídas em Python <http://www.celeryproject.org/>

¹³Plataforma Open Source de Mensageria <https://www.rabbitmq.com/>

¹⁴Sistema de mensageria da plataforma de AWS <https://aws.amazon.com/sqs/>

- **Redis**¹⁵: Após a escolha de qual biblioteca iríamos usar para facilitar a tarefa de filas de trabalho, que foi o Celery, foi preciso escolher algum componente para a mensageria do projeto, ou seja, o componente que realmente é responsável por armazenar e distribuir as mensagens relacionadas aos trabalhos submetidos na solução. Entre as opções estavam RabbitMQ, Redis e Amazon SQS. Essas as que melhor se integravam com o celery, sendo possível obter todas as suas funcionalidades com qualquer um desses três. Porém, Amazon SQS é uma opção presa a um provedor de nuvem, o que complica o andar do projeto, caso seja preciso usar outra cloud diferente da AWS. RabbitMQ e Redis ofereciam funcionalidades muito parecidas, porém o Redis foi escolhido, devido a infinidade de materiais sobre o uso dele e suas outras funcionalidades que podem ser tiradas proveito também, como, por exemplo, cache e armazenamento de dados em memória.
- **MongoDB**¹⁶: Para o armazenamento dos dados de cadastro de usuários, informações sobre argumentos de cada tipo de binário e etc, a escolha foi um banco de dados NoSQL(referencia), o MongoDB. A escolha deste foi muito direta, uma vez que os dados que estavam trafegando entre um serviço e outro tinham uma estrutura muito parecida com os documentos que são guardados nesse tipo de banco, não sendo necessário de preocupar em transformar os dados para os esquemas presentes em tabelas SQL(referencia), o que agiliza muito o trabalho.
- **Blob Storage**¹⁷: o Blob Storage do Microsoft Azure foi a opção aqui pois era necessário uma espécie de armazenamento de propósito geral. Aqui ele está sendo usado para armazenamento dos dados sísmicos e binários. Foi escolhido devido a excelente integração que possui com Python. Outras opções existentes eram, por exemplo, Amazon S3(link), que oferece serviços muito parecidos. Outra opção era deixar esses dados em no disco de máquinas virtuais e servi-los por meio de servidores, porém, isso aumentaria muito a complexidade e dificultaria a tarefa de gerenciar esse tipo de infraestrutura.

4.3 Ferramentas para Deploy

Como dito anteriormente, ao iniciar o projeto, não era desejado que estivéssemos presos a um modelo específico de deployment. Assim, para facilitar o deploy da aplicação independente do modo que foi escolhido para o deploy, foi criado uma série de scripts em ferramentas específicas para ajudar. Existem dois modelos que estão sendo facilitados:

- **Kubernetes**¹⁸: Orquestrador de Containers extremamente famoso nos dias de hoje, que tem como principal funcionalidade tornar mais simples, escalável e performática o deploy de aplicações baseadas em Containers. Nascida dentro do Google, a partir

¹⁵Armazenamento de dados em memória Open Source <https://redis.io/>

¹⁶Banco de Dados NoSQL Open Source <https://www.mongodb.com/>

¹⁷Armazenamento de caráter genérico no Microsoft Azure <https://azure.microsoft.com/en-us/services/storage/blobs/>

¹⁸Orquestrador de Containers Open Source <https://kubernetes.io/>

do Borg, que segundo o paper publicado pelo Google [5], é um gerenciador de cluster que roda centenas de milhares de processamentos, de milhares de diferentes aplicações entre uma série de clusters, atualmente está sob a jurisdição da Cloud Native Foundation¹⁹ e é Open Source. Foi uma das plataformas que foi visada por ter apresentado extremamente relevância nos últimos tempos, com todos os grandes provedores de Nuvem oferecendo opções gerenciadas dessa ferramenta.

- **Ansible**²⁰: um modelo muito comum de deploy de aplicações é baseada em máquinas virtuais. Nesse caso, é bom garantir que todas as dependências necessárias para que a aplicação rode com sucesso estejam instaladas. Nesse aspecto, o Ansible se mostra extremamente eficaz. Essa ferramenta surgiu da Red Hat e também é mantida Open Source, sendo um ótimo gerenciador de configurações, que torna possível escrever configurações como código, o que garante que a aplicação sempre terá sucesso para ser executada.

5 Resultados

5.1 Arquitetura

Após seguir todo o experimento citado acima, foi alcançado um resultado muito próximo do esperado. A arquitetura final do projeto, está mostrada na figura (linkar a figura).

Dada a arquitetura final do projeto mostra na figura 8 os componentes mostrados tem, cada um, a seguinte função:

- **Web Client:** componente que roda no lado do cliente. Seguimos com o que foi proposto no início do projeto e explicado durante o procedimento, ou seja, todo o código do lado do cliente foi escrito em Typescript, com o auxílio do framework Angular, a estilização das páginas foi feita com Bootstrap e servido via Nginx.
- **Flask Back End:** responsável por receber todas as requisições que saem do front end. Funciona como um gateway (talvez uma citação). Também foi seguido o plano inicial de escrever todo o back end com Python, Flask e Celery. Esse é o componente que possui mais responsabilidades: autenticação, comunicação com a fila com o auxílio do Celery, acesso aos Blobs e acesso ao banco.
- **Linux Workers:** Componentes que são responsáveis pela execução propriamente dita dos pedidos. Com o auxílio do Celery, esperam por pedidos entrarem na fila, e assim que isso acontece, executam. É possível ter um cluster de máquinas com esse papel, aumentando o paralelismo das execuções.
- **Message queue with Redis:** também parte do plano inicial, a fila de mensagens com o Redis foi a maneira mais eficaz e resiliente que encontramos de desacoplar o back end dos Linux workers. Assim o back end somente precisava submeter uma

¹⁹Cloud Native Computing Foundation <https://www.cncf.io/>

²⁰Gerenciador de configuração Open Source <https://www.ansible.com/>




Figura 8: Arquitetura final do projeto

mensagem com as definições para a execução de um trabalho na fila e algum worker pegaria essa requisição e faria o processamento necessário. Aqui vale uma observação importante. A escolha do Celery e do modelo de filas de trabalhos distribuídas, que já foi explicada anteriormente, torna possível, além de desacoplar o back end dos workers, ainda torna possível a execução de processamentos em paralelo e distribuídos, não criando um gargalo na solução, possivelmente ocasionado pelo grande número de pedidos na fila esperando por um único worker.

- **toolsCollection:** coleção dentro do banco que guarda informações sobre os binários que estão armazenados. Novos dados são inseridos nela quando submetidos um novo binário é armazenado, quando um novo pedido de processamento será incluído, já que é necessário consultar quais os parâmetros para esse e também quando um binário é excluído, apagando o registro. O modelo que está sendo usado para guardar essas informações é o que está na figura 9
- **resultsCollection:** coleção de documentos no banco para guardar os dados do resultado, armazena o id do processamento, dado e binário usado, além dos argumentos. Essa coleção é acessada após o término de cada processamento, para salvar as informações do resultado e também quando é desejado que todos os resultados sejam

```
{
  "_id" : ObjectId("5be74b71c0f26007790bc37d"),
  "args" : [
    {
      "description" : "Azimute (em graus) do dado sol",
      "name" : "1"
    },
    {
      "description" : "Velocidade inicial",
      "name" : "2"
    },
    {
      "description" : "Velocidade final",
      "name" : "3"
    },
    {
      "description" : "Step da velocidade",
      "name" : "4"
    },
    {
      "description" : "Abertura limite em meio afastamento (Semblance)",
      "name" : "5"
    },
    {
      "description" : "Abertura limite em meio afastamento (Empilhamento)",
      "name" : "6"
    },
    {
      "description" : "Dado prestack",
      "name" : "7"
    },
    {
      "description" : "Pasta de armazenamento dos dados postack",
      "name" : "8"
    }
  ],
  "name" : "cmp"
}
```

Figura 9: Modelo presente na coleção de ferramentas binárias

```
{
  "_id" : ObjectId("5be7726ec0f2600daa14e026"),
  "tool" : "cmp",
  "data" : "sol.su",
  "id" : "4b1785ef-485e-4a96-8fd2-0fa5ec929f8b",
  "args" : {
    "1" : "0.0",
    "2" : "1500.0",
    "3" : "4500.0",
    "4" : "50.0",
    "5" : "2000.",
    "6" : "2000.",
    "7" : "sol.su",
    "8" : "sol"
  }
}
```

Figura 10: Modelo presente na coleção de resultados

mostrados na tela de gerenciamento de resultados. O modelo segue o padrão da figura 10.

```
{
  "_id" : ObjectId("5bb1464ec0f26014a6c8fc70"),
  "password" : "123",
  "email" : "guilhermepic.com"
}
```

Figura 11: Modelo presente da coleção de usuários

- **usersCollection:** usada para armazenamento de dados dos usuários, como senha e email para autenticação. Um novo registro é criado nessa coleção quando um usuário cria uma nova conta. A coleção também é acessada para autenticação de um novo usuário. Para que todos esses processos sejam executados com sucesso, o modelo

usado é o da figura 11.

- **seismic-tools:** Blob usado para armazenar os binários submetidos pelos usuário. Acessado pelo componente de gerenciamento de ferramentas quando uma nova ferramenta é inserida na plataforma e quando o processamento vai acontecer, pois nesse momento é necessário baixar esses dados para execução em um dos workers.
- **seismic-data:** Blob que armazena os dados sísmicos submetidos. Também são acessados pelo componente de gerenciamento de dados quando um novo dado é incluído, excluído e na execução dos trabalhos, já que é necessário baixar esses dados.
- **seismic-results:** Outro blob. Esse, responsável por armazenar os resultados dos processamentos. Todos os resultados são empacotados em um arquivo tar.gz²¹ e disponibilizados para download, no componente responsável por gerenciar os resultados.

Vale notar aqui que, usamos somente uma instância de bancos de dados, com coleções diferentes para cada tipo de aplicação, as Collections, no caso. Também usamos a mesma estratégia para o blob. Foi usada somente uma conta de armazenamento no Microsoft Azure, com pastas separadas para cada uso, que no caso, são seismic-data, seismic-tools e seismic-results.

5.2 Telas finais

Assim, após apresentar a arquitetura final, são apresentadas os componentes, com suas respectivas telas.

Figura 12: Tela final do login

Na tela final de login, figura 12, existe dois campos muito simples e comuns em sites que necessitam autenticação: email e senha. Além disso, caso você não possua uma conta, é possível criar uma no canto superior direito.

Caso, na tela de login, for escolhido a tela que o usuário será direcionado é a 13, onde será possível criar uma nova conta com email e senha, que deve ser confirmada. Aqui, existe a verificação se o email já foi usado, para garantir que cada usuário só tenha uma conta cadastrada.

Na imagem 14 é possível observar como todas as funcionalidades que foram planejadas no início estão sendo contempladas. Na seção de Upload, é possível definir um nome para o dado, e escolher o arquivo que será submetido. Além disso, a tabela abaixo mostra todos

²¹<https://www.gzip.org/>

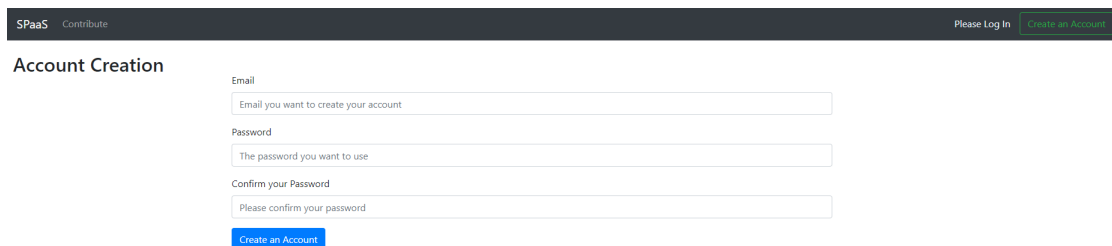
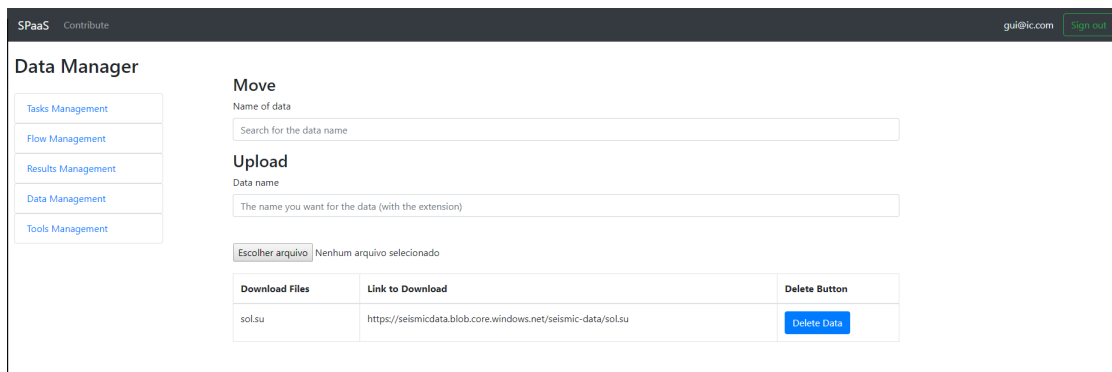


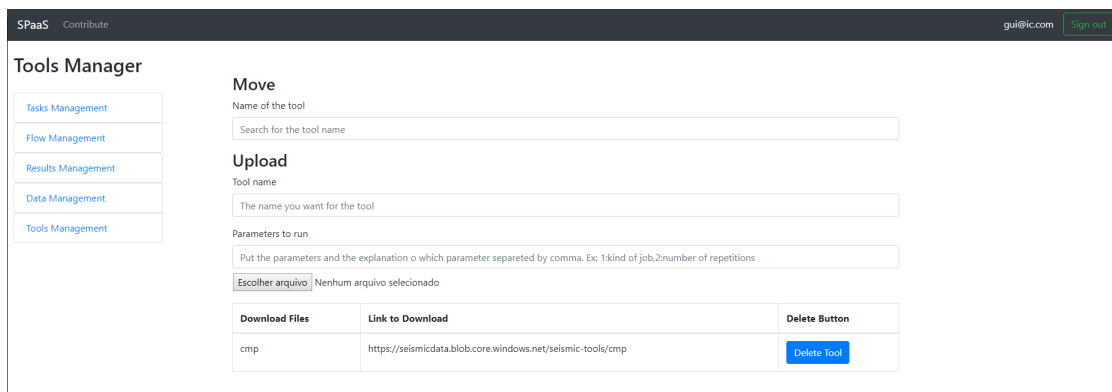
Figura 13: Tela final de criação de contas



Download Files	Link to Download	Delete Button
sol.su	https://seismicdata.blob.core.windows.net/seismic-data/sol.su	Delete Data

Figura 14: Tela final de gerenciamento de dados sísmicos

os dados que foram submetidos, com o link para download e também a opção de deletar os já existentes.



Download Files	Link to Download	Delete Button
cmp	https://seismicdata.blob.core.windows.net/seismic-tools/cmp	Delete Tool

Figura 15: Tela final de gerenciamento de binários

Extremamente parecida com a tela referente aos dados, a figura 15 mostra a tela de gerenciamento dos binários que foram submetidos para a plataforma. Aqui também deve ser selecionado um arquivo, um nome e quais os parâmetros necessários para a execução, juntamente com suas explicações. Assim, os parâmetros são submetidos da seguinte maneira:

1:explicação do parâmetro 1, 2:explicação do parâmetro 2, etc.

The screenshot shows the SPaaS Tasks Manager interface. On the left, there is a sidebar with a 'Tasks Manager' header and a list of links: 'Tasks Management', 'Flow Management', 'Results Management', 'Data Management', and 'Tools Management'. The main area is titled 'Tool' and contains a 'Tool name' dropdown menu. Below it, there is a 'Data' dropdown menu and a 'Submit Task' button.

Figura 16: Tela final de gerenciamento de processamentos

The screenshot shows the SPaaS Tasks Manager interface with a detailed form. The sidebar is the same as in Figure 16. The main area is titled 'Tool' and contains a 'Tool name' dropdown menu with 'cmp' selected. Below it, there are eight numbered input fields: 1. 'Azimute (em graus) do dado sol', 2. 'Velocidade inicial', 3. 'Velocidade final', 4. 'Step da velocidade', 5. 'Abertura limite em meio afastamento (Semblance)', 6. 'Abertura limite em meio afastamento (Empilhamento)', 7. 'Dado prestack', and 8. 'Pasta de armazenamento dos dados postack'. Below these fields is a 'Data' dropdown menu and a 'Submit Task' button.

Figura 17: Tela final de processamento detalhada

A figura 16 mostra como é a definição de um pedido de processamento que será submetido. Nesse primeiro momento, só é possível escolher um binário e o dado que serão usados, porém como mostra a figura 17, após selecionar o binário que será executado serão automaticamente carregados quais são os argumentos necessários para a execução com sucesso dessa tarefa. Esses argumentos foram submetidos juntamente com o binário na tela representada pela figura 15.

Na tela de resultados, representada pela figura 18, fica claro como podemos obter os resultados depois de terminados com sucesso os processamentos. Além disso, caso o usuário queira verificar quais foram os dados, binários e argumentos que geraram aqueles resultados é possível através do botão de details, que gera o json com as características daquele processamento, como é possível ver na figura 19.




Figura 18: Tela final de gerenciamento de resultados

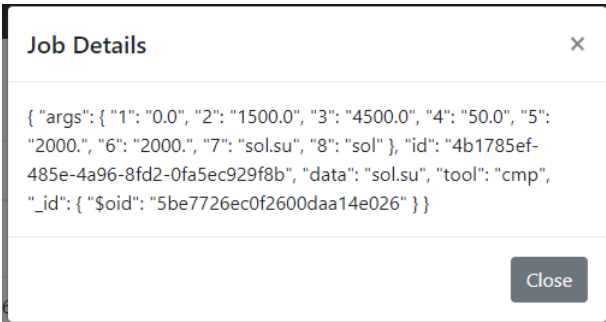


Figura 19: Tela final com detalhes do processamento nos resultados

Referências

[1] B. Burns, *Designing Distributed Systems*, O'Reilly Media (2017).

[2] B. Perens et al., *Debian Social Contract*, (1997).

[3] A. Verma, L. Pedrosa et al., *Large-scale cluster management at Google with Borg*, (2015).

[4] A. Verma, L. Pedrosa et al., *Cloud Computing Security: A Systematic Literature Review*, (2015).

[5] K. Paladugu and S. Mukka, *Systematic Literature Review and Survey on High Performance Computing in Cloud*, (2012).